



Pembelajaran Mesin

LAPORAN PROYEK

Machine Learning

Klasifikasi Penyakit Pada Daun Kopi



Oleh :

11422055	Yen Rylin Hutasoit
11422006	Melvayana Manik
11422028	Nehemia Sitorus
11422027	Mega Paramita Malau
11422056	Joice Sharon Sinaga

**FAKULTAS VOKASI
INSTITUT TEKNOLOGI DEL**

1. Latar Belakang

Kopi adalah salah satu komoditas pertanian yang memiliki nilai ekonomi yang tinggi, terutama di negara-negara penghasil kopi seperti Indonesia. Selain menjadi sumber pendapatan bagi petani, kopi juga berkontribusi pada perekonomian nasional. Penyakit yang menyerang tanaman kopi dapat menyebabkan kerugian yang cukup besar. Secara tradisional, identifikasi penyakit dilakukan secara manual oleh petani atau ahli pertanian. Namun, metode ini memiliki beberapa kendala dalam waktu dan tenaga yaitu proses identifikasi memerlukan waktu yang lama dan keterampilan khusus dan juga kesalahan manusia yaitu ada kemungkinan terjadinya kesalahan dalam diagnosis, yang dapat berdampak negatif pada hasil panen. Pengenalan dini dan diagnosis hama atau penyakit pada tanaman kopi sangat penting untuk meminimalkan dampaknya terhadap kualitas dan hasil tanaman [1].

Dengan kemajuan teknologi, khususnya dalam bidang kecerdasan buatan, mesin learning dapat dimanfaatkan untuk membantu dalam mendeteksi penyakit pada tanaman. Beberapa keuntungan dari penggunaan mesin learning antara lain: Akurasi tinggi: algoritma dapat dilatih untuk mengenali pola tertentu dalam citra daun, kecepatan: proses identifikasi dapat dilakukan dengan cepat dan efisien, skalabilitas: dapat diterapkan pada berbagai ukuran kebun, dari yang kecil hingga perkebunan besar.

Klasifikasi adalah proses untuk membangun model atau fungsi yang menggambarkan konsep suatu data. Dalam proses klasifikasi, sejumlah data dikumpulkan dan dibagi menjadi kategori-kategori tertentu yang disebut class. Kelas yang terbentuk ini dikenal sebagai dataset pelatihan, yang akan dipelajari oleh algoritma klasifikasi. Salah satu algoritma yang efektif untuk tugas ini adalah Convolutional Neural Network (CNN), khususnya dengan menggunakan arsitektur ResNet50. Proses ini disebut pelatihan atau training, di mana model dilatih untuk mengenali pola dalam data, sehingga dapat mengklasifikasikan data baru dengan akurasi yang lebih tinggi.

Pengembangan sistem mesin learning untuk identifikasi penyakit daun kopi bertujuan untuk meningkatkan efisiensi dan akurasi dalam mendeteksi penyakit. Dengan memanfaatkan teknologi mesin learning, diharapkan dapat membantu petani kopi mengatasi tantangan penyakit tanaman, meningkatkan hasil panen, dan pada akhirnya mendukung keberlanjutan industri kopi.

2. Kajian Pustaka

Kopi Ateng merupakan yang dominan selain kopi yang berjenis Arabika dan Robusta di daerah Toba. Petani banyak menanam kopi Ateng karena umur produksinya yang relatif cepat, kemudian dapat dijual dalam bentuk gelondong merah (cherry red). [2]. Kopi Ateng sering digunakan dalam berbagai produk kopi, baik dalam bentuk biji utuh maupun bubuk. Varietas ini juga sering diolah menjadi kopi specialty yang diminati banyak konsumen.

Penyakit Tanaman Kopi:

1. Pengorok daun (Leaf Miner)

Penyakit yang di kenal sebagai *Leaf Miner* menyerang daun kopi karena disebabkan oleh serangan *Leucoptera Caffeine*, juga dikenal sebagai hama penambang daun. Terdapat ciri ciri bekas loreng atau jalur menggulung yang terlihat di permukaan daun. Ini seperti jejak yang ditinggalkan serangga kecil di sepanjang daun [3].



Gambar 1. Contoh Pengorok daun

2. Karat Daun (Leaf Rust)

Penyakit yang di kenal sebagai *Leaf Rust* atau karat daun pada tumbuhan disebabkan oleh golongan jamur yang masuk dalam *Ordo Pucciniale*. Penyakit karat daun memiliki ciri-ciri yang pada sisi bawah daun terdapat bercak-bercak yang semula berwarna kuning muda, kemudian menjadi kuning tua, hingga membentuk tepung yang berwarna jingga cerah [4].



Gambar 2. Contoh Karat daun

3. Hawar Daun (Phoma)

Hawar daun merupakan penyakit pada daun kopi yang disebabkan oleh jamur *Phoma Costaricensis*, ciri-cirinya terdapat noda berbentuk lingkaran hitam pada permukaan daun kopi yang terkonsentrasi di satu area yang cukup besar pada daun atau ditengah daun, seperti daun yang bolong atau rusak parah [5].



Gambar 3. Contoh Hawar daun

4. Bercak Daun (Cercospora)

Bercak pada daun kopi disebabkan oleh jamur *Cercospora coffeicola*. Pada daun terdapat bercak-bercak bulat yang terlihat seperti noda yang berwarna coklat atau kehitaman biasanya berada di

permukaan daun secara acak dan tidak beraturan, tapi tidak sampai merusak struktur daun secara ekstrem [6], [7].



Gambar 4. Bercak daun

2.1 Machine Learning

Machine Learning adalah cabang dari AI yang fokus belajar dari data (learn from data), yaitu fokus pada pengembangan sistem yang mampu belajar secara “mandiri” tanpa harus berulang kali diprogram manusia. Machine Learning membutuhkan Data yang valid ketika proses training sebelum digunakan ketika testing untuk hasil output yang optimal. Machine Learning memungkinkan mesin untuk menganalisis data, mengidentifikasi pola, dan membuat prediksi atau Keputusan berdasarkan informasi yang telah dipelajari sebelumnya.

Machine learning dapat digunakan dalam berbadai aplikasi, termasuk pada pengklasifikasian penyakit tanaman pada daun kopi. Teknologi ini memanfaatkan algoritma untuk menganalisis citra daun dan mengidentifikasi berbagai jenis penyakit berdasarkan pola yang terdapat pada daun.

2.2 Supervised Learning

a. Pengertian Supervised Learning

Supervised Learning adalah metode dalam machine learning di mana model dilatih menggunakan dataset yang memiliki label, yaitu data yang sudah diketahui input (features) dan output-nya (target) [8]. Metode ini bertujuan untuk mempelajari hubungan antara input dan output sehingga model dapat digunakan untuk memprediksi hasil dari data baru yang belum pernah ditemukan sebelumnya, model belajar dari contoh-contoh yang diberikan untuk menghasilkan prediksi atau klasifikasi yang akurat. Supervised learning sering digunakan dalam berbagai aplikasi, termasuk klasifikasi dan regresi, dan merupakan salah satu metode yang paling banyak digunakan dalam kecerdasan buatan. [9]

b. Jenis Algoritma Supervised Learning

Beberapa algoritma yang sering digunakan dalam supervised learning

1. Decision Tree: Algoritma ini membagi dataset menjadi subset berdasarkan nilai fitur, membentuk struktur pohon keputusan. Decision tree mudah dipahami dan diinterpretasikan.

2. Linear Regression: Digunakan untuk masalah regresi, linear regression memodelkan hubungan antara variabel independen dan dependen dengan cara menemukan garis terbaik yang sesuai dengan data.
3. Logistic Regression: Algoritma ini digunakan untuk klasifikasi biner dengan memodelkan probabilitas bahwa suatu input termasuk dalam kategori tertentu
4. Support Vector Machine (SVMs): SVM berusaha menemukan hyperplane terbaik yang memisahkan kelas-kelas dalam data. Ini sangat berguna untuk masalah klasifikasi dengan margin maksimum.

c. Tahapan Umum Supervised Learning

Beberapa tahapan umum supervised learning

1. Pengumpulan Data: Mengumpulkan dataset yang relevan, termasuk input (fitur) dan output (label). Dataset ini harus representatif untuk masalah yang ingin diselesaikan.
2. Persiapan Model: Melakukan pembersihan dan preprocessing data, termasuk menangani nilai hilang, normalisasi, dan pembagian dataset menjadi set pelatihan dan set pengujian.
3. Pelatihan Model: Menggunakan data pelatihan untuk melatih model dengan algoritma yang dipilih. Pada tahap ini, model belajar dari hubungan antara input dan output.
4. Evaluasi Model: Setelah model dilatih, langkah selanjutnya adalah mengevaluasi kinerjanya menggunakan data pengujian. Metode evaluasi bisa berupa akurasi, presisi, recall, atau F1-score tergantung pada jenis masalahnya.
5. Tuning Model: Melakukan penyesuaian parameter model (hyperparameter tuning) untuk meningkatkan akurasi atau performa model berdasarkan hasil evaluasi.
6. Implementasi Model: Setelah model dianggap cukup baik, model dapat diterapkan pada data baru untuk membuat prediksi atau Keputusan.
7. Pemeliharaan Model: Secara berkala melakukan pemantauan dan pembaruan model agar tetap relevan dengan data terbaru dan perubahan pola dalam data.

2.3 Neural Network

Neural Network, atau jaringan saraf tiruan, adalah salah satu teknologi komputasi yang terinspirasi oleh cara kerja otak manusia. Jaringan ini terdiri dari sejumlah unit pemrosesan yang disebut neuron, yang saling terhubung dan bekerja sama untuk memproses informasi. Meskipun Neural Network tidak memberikan keajaiban secara langsung, penerapannya yang tepat dapat menghasilkan hasil yang luar biasa dalam berbagai bidang [10].

Neural Network terdiri dari beberapa lapisan, yaitu lapisan input, hidden layer dan lapisan output. Setiap neuron dalam lapisan terhubung dengan neuron di lapisan berikutnya melalui bobot yang dapat disesuaikan. Proses pembelajaran dalam Neural Network terjadi melalui pelatihan, di mana model belajar dari data yang diberikan dengan menyesuaikan bobot-bobot ini untuk meminimalkan kesalahan dalam prediksi.

1. Lapisan Input

Lapisan pertama yang menerima data mentah. Setiap neuron di lapisan ini mewakili fitur dari data yang akan diproses. Lapisan ini berguna untuk menampung pixel value dari citra yang

diinputkan. Citra batik tanah liat yang telah diinputkan memiliki 3 channel warna RGB (Red, Green, Blue) [11].

2. Hidden Layer

Lapisan ini berfungsi untuk mengekstrak fitur-fitur yang lebih kompleks dari data. Jumlah lapisan tersembunyi dan neuron di dalamnya dapat bervariasi tergantung pada kompleksitas masalah yang ingin diselesaikan.

3. Lapisan Output

Lapisan terakhir yang menghasilkan output dari model. Jumlah neuron di lapisan ini biasanya sesuai dengan jumlah kelas dalam masalah klasifikasi atau satu neuron untuk masalah regresi.


Proses pembelajaran dalam Neural Network umumnya dilakukan melalui algoritma backpropagation. Dalam algoritma ini, kesalahan output dihitung dan disebarkan kembali ke seluruh jaringan untuk memperbarui bobot. Proses ini diulang berkali-kali hingga model mencapai tingkat akurasi yang diinginkan.

Kelebihan Neural Network termasuk kemampuannya untuk menangani data yang tidak terstruktur, fleksibilitas dalam arsitektur, dan kemampuan untuk belajar dari data besar. Namun, ada juga beberapa kekurangan, seperti kebutuhan akan data yang besar untuk pelatihan, waktu komputasi yang lama, dan kesulitan dalam interpretasi hasil [10].

2.4 Convolutional Neural Network

Convolutional Neural Network (CNN) adalah sistem kecerdasan buatan berbasis jaringan saraf multi-layer yang dapat mengidentifikasi, mengenali, dan mengklasifikasikan objek, serta mendeteksi dan melakukan segmentasi pada objek dalam gambar. CNN merupakan salah satu arsitektur deep learning yang dirancang khusus untuk menangani berbagai bentuk 2D [12].

CNN merupakan salah satu jenis arsitektur neural network yang dirancang secara khusus untuk menangani data visual seperti citra digital. Berbeda dengan neural network tradisional yang memproses data secara fully connected, CNN memanfaatkan operasi konvolusi dan pooling untuk mengekstrak fitur-fitur visual dari input gambar secara efektif.



Gambar 5. Arsitektur Model CNN

Komponen-komponen yang ditunjukkan dalam diagram, seperti Convolution Layers, MaxPooling 2D, Flatten Layer, Batch Normalization, dan Dense Layers, merupakan lapisan-lapisan khas yang ditemukan dalam arsitektur CNN. Melalui susunan lapisan-lapisan ini, CNN mampu mempelajari representasi fitur yang relevan dari data citra, sehingga dapat digunakan untuk tugas-tugas klasifikasi, deteksi objek, dan lain-lain [13].

Convolution Layers

Lapisan konvolusi adalah lapisan dasar dalam CNN yang berfungsi untuk mengekstrak fitur-fitur visual dari input gambar. ekstraksi fitur terhadap data input [9]. Ekstraksi fitur dilakukan melalui proses konvolusi yang melibatkan kumpulan filter dua dimensi dan fungsi aktivasi tertentu untuk menghasilkan feature map [14].

MaxPooling 2D

Lapisan MaxPooling 2D berfungsi untuk melakukan downsampling pada fitur-fitur yang telah diekstrak oleh lapisan konvolusi. Ini bertujuan untuk mengurangi dimensi spasial dari fitur, sehingga mengurangi jumlah parameter yang harus dipelajari [15].

Flatten Layer

Lapisan Flatten berfungsi untuk mengubah output dari lapisan MaxPooling 2D menjadi vektor satu dimensi, sehingga dapat dihubungkan ke lapisan fully connected (Dense Layers) [1]

Batch Normalization

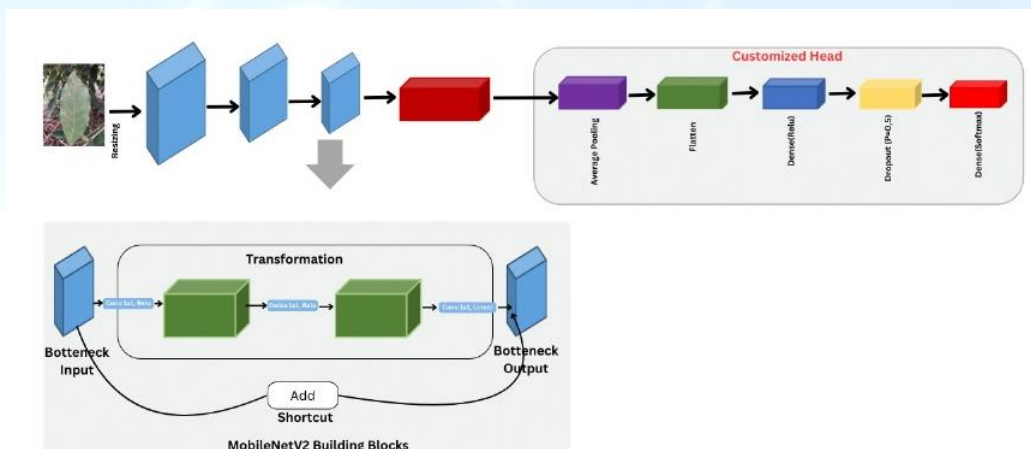
Lapisan Batch Normalization berfungsi untuk mempercepat proses pelatihan dengan cara melakukan normalisasi pada input dari setiap lapisan [12].

Dense Layers

Lapisan Dense (fully connected) adalah lapisan terakhir dalam arsitektur CNN. Lapisan ini berfungsi untuk melakukan klasifikasi atau prediksi berdasarkan fitur-fitur yang telah diekstrak oleh lapisan sebelumnya [1].

a. MobileNet V2

MobileNetV2 adalah sebuah arsitektur jaringan saraf konvolusional (CNN) yang dirancang khusus untuk lingkungan seluler dan perangkat dengan sumber daya terbatas.[16]. MobileNetV2 yang dirilis pada tahun 2018 masih menggunakan depth wise dan point wise konvolusi seperti pada versi sebelumnya, namun MobileNetV2 menambahkan dua fitur baru yaitu linear bottleneck dan shortcut connections antar layer [17]. Arsitektur MobileNetV2 dikembangkan dengan tujuan utama efisiensi komputasi dan penggunaan sumber daya yang rendah.



Gambar 6. Arsitektur MobileNetV2

Arsitektur ini terdiri dari blok bangunan yang menggunakan operasi konvolusi depthwise, konvolusi pointwise, dan sambungan shortcut. Konvolusi depthwise memungkinkan

pemrosesan yang lebih efisien dengan menggunakan sumber daya yang lebih sedikit, sementara konvolusi pointwise menggabungkan informasi dari berbagai saluran untuk mempelajari representasi yang lebih kompleks dengan biaya komputasi yang rendah [18]. Sambungan shortcut memungkinkan aliran informasi yang lebih baik melalui lapisan, meningkatkan efisiensi dan kinerja model. Tujuan utama desain MobileNetV2 adalah untuk menghasilkan model yang efisien secara komputasi dan penggunaan sumber daya, sehingga cocok untuk digunakan pada perangkat seluler dan perangkat dengan sumber daya terbatas [19].

b. ResNet-50

ResNet-50 adalah jenis jaringan saraf konvolusional (CNN) yang telah merevolusi cara kita mendekati pembelajaran mendalam. Jaringan ini pertama kali diperkenalkan pada tahun 2015 oleh Kaiming He dkk. di Microsoft Research Asia. ResNet merupakan singkatan dari residual network yang merujuk pada blok-blok residual yang menyusun arsitektur jaringan. ResNet-50 didasarkan pada kerangka kerja pembelajaran residual mendalam yang memungkinkan pelatihan jaringan sangat dalam dengan ratusan lapisan. ResNet-50 salah satu arsitektur yang memiliki konsep shortcut connection yang digunakan untuk mencegah sistem dari hilangnya banyak informasi di saat training dilakukan [13]. ResNet-50 memiliki beberapa keunggulan, termasuk kemampuan untuk melatih jaringan yang sangat dalam dengan ratusan lapisan, mencapai hasil terkini dalam berbagai tugas terkait gambar, dan penggunaan koneksi lewati untuk pelestarian informasi dari lapisan sebelumnya. ResNet-50 telah terbukti mengungguli jaringan lain dalam berbagai tugas terkait gambar, termasuk deteksi objek, klasifikasi gambar, dan segmentasi gambar. Penggunaan blok residual dan koneksi lewati menjadikannya pilihan yang kuat dan efisien untuk pembelajaran mendalam dalam visi komputer [20].

Jaringan ini terdiri dari beberapa lapisan, dimulai dengan lapisan konvolusional yang melakukan konvolusi pada citra masukan, diikuti oleh lapisan pengumpulan maksimum yang melakukan downsampling pada hasil konvolusi. Keluaran dari lapisan ini diteruskan melalui serangkaian blok residual, di mana setiap blok terdiri dari dua lapisan konvolusional yang masing-masing disertai dengan normalisasi batch dan fungsi aktivasi ReLU. Output dari lapisan konvolusional kedua dalam blok ditambahkan kembali ke input blok tersebut sebelum diteruskan melalui fungsi aktivasi ReLU lainnya. Akhirnya, jaringan diakhiri dengan lapisan yang terhubung penuh yang mengambil keluaran dari blok residual terakhir dan memetakan hasilnya ke kelas keluaran, dengan jumlah neuron dalam lapisan ini sesuai dengan jumlah kelas yang ada [13].

2.5 Image Classification

Image classification adalah proses mengelompokkan gambar ke dalam kategori tertentu berdasarkan karakteristik yang dapat diambil dari gambar [21]. Contoh classification ini meliputi pola, warna, tekstur, dan elemen lain yang tercermin dalam data visual. Komponen penting dari bidang computer vision yang memungkinkan mesin mengenali dan memahami gambar dengan cara yang mirip dengan manusia [15].

Tabel 1. Image Classification

Jenis Penyakit	Sample Daun Kopi
----------------	------------------

Pengorok daun (Leaf Miner)




Karat Daun (Leaf Rust)



Hawar Daun (Phoma)



Bercak Daun (Cercospora)



2.6 Feature extraction

Feature extraction adalah tahap penting dalam proses klasifikasi citra yang bertujuan untuk mengubah citra mentah menjadi representasi numerik yang dapat digunakan oleh algoritma pembelajaran mesin untuk melakukan klasifikasi [12]. Dalam konteks deteksi penyakit pada tanaman kopi, fitur yang diekstraksi dari citra daun akan digunakan untuk membedakan daun yang sehat dan yang terinfeksi penyakit. Proses ekstraksi fitur ini melibatkan identifikasi pola, tekstur, warna, dan bentuk yang ada dalam citra [4].

Feature Extraction bertujuan untuk:

1. **Meningkatkan Kinerja Model:** Feature extraction bertujuan untuk meningkatkan akurasi model machine learning dengan menyediakan fitur yang lebih informatif dan relevan. Fitur yang diekstrak dapat berupa kata-kata kunci, entitas, atau atribut lain yang berhubungan dengan analisis yang dilakukan [22].
2. **Mengurangi Dimensi Data:** Dengan mengekstrak fitur yang paling penting, feature extraction membantu mengurangi dimensi data. Ini penting untuk menghindari masalah overfitting dan mempercepat proses pelatihan model [22].
3. **Mendukung Klasifikasi dan Pengelompokan:** Feature extraction juga digunakan dalam berbagai aplikasi klasifikasi, seperti pengenalan wajah atau deteksi objek, di mana fitur-fitur yang diekstrak membantu model dalam membedakan antara kelas-kelas yang berbeda [23].

2.7 Transfer Learning

Transfer learning adalah suatu pendekatan dalam pembelajaran mesin yang memungkinkan model untuk memanfaatkan pengetahuan yang diperoleh dari satu tugas (domain sumber) dan menerapkannya pada tugas lain yang berbeda (domain target). Transfer learning melakukan modifikasi dan mengupdate parameter-parameter pada network tersebut. Transfer learning menjadikan network yang telah termodifikasi sebagai pembelajaran dengan tugas berbed [17]. Pendekatan ini sangat berguna ketika data yang tersedia untuk domain target terbatas, sehingga tidak memungkinkan untuk melatih model dari awal dengan akurasi yang baik. Dalam konteks industri,

transfer learning sangat relevan karena seringkali sulit untuk mengumpulkan data berlabel dalam jumlah besar untuk setiap variasi proses industri. Dengan transfer learning, model yang telah dilatih pada tugas atau domain yang serupa dapat diadaptasi untuk tugas baru dengan sedikit atau tanpa data berlabel tambahan. Ini mengurangi kebutuhan untuk pelatihan ulang yang memakan waktu dan biaya, serta memungkinkan sistem deteksi anomali berfungsi secara efektif meskipun dalam kondisi yang dinamis dan berubah-ubah. Transfer learning dapat dibagi menjadi beberapa kategori, termasuk inductive transfer learning, di mana tugas target berbeda dari tugas sumber, dan transductive transfer learning, di mana tugasnya sama tetapi distribusi data berbeda. Dengan memanfaatkan pengetahuan yang diperoleh dari tugas sebelumnya, transfer learning membantu meningkatkan kinerja model pada tugas baru, sehingga memberikan solusi yang lebih efisien dan efektif dalam mendeteksi anomali dalam data waktu nyata di lingkungan industri [4].

2.8 Model Optimization

Model optimization adalah proses penyempurnaan model pembelajaran mesin untuk meningkatkan performa prediksi, efisiensi komputasi, atau kemampuan generalisasi. Dalam konteks pembelajaran mesin, optimisasi bertujuan meminimalkan fungsi loss (kerugian) yang mengukur sejauh mana prediksi model menyimpang dari nilai sebenarnya. Proses ini melibatkan berbagai teknik, mulai dari pengaturan parameter hingga pemilihan arsitektur yang optimal [21].

Hyperparameter Tuning

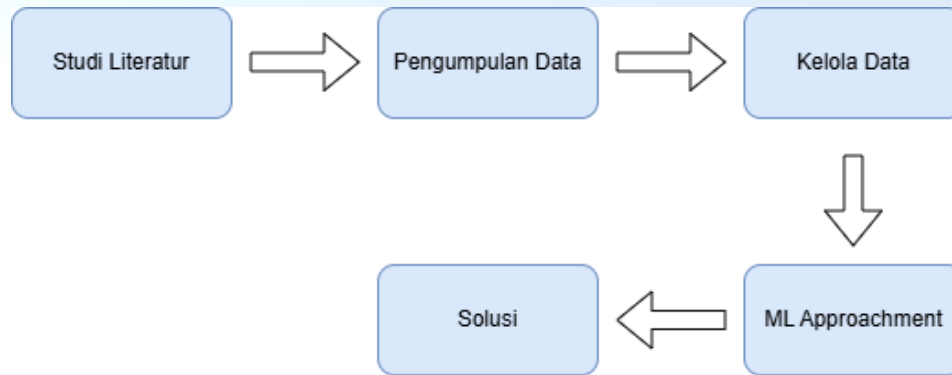
Proses memilih nilai terbaik untuk hyperparameter, seperti learning rate, jumlah layer dalam neural network, atau ukuran batch, untuk meningkatkan performa model. Pendekatan yang umum digunakan adalah Grid Search, Random Search, dan algoritma berbasis Bayesian Optimization.

3. Metode Penelitian

Dalam penelitian ini menggunakan pendekatan supervised learning dengan memanfaatkan deep learning berbasis Convolutional Neural Network (CNN). Dua model yang digunakan adalah MobileNetV2 dan ResNet50. Penelitian ini memanfaatkan gambar penyakit daun kopi sebagai data latih dengan 4 label yang menunjukkan jenisnya.

3.1 Diagram Penelitian

Diagram penelitian adalah representasi visual yang menggambarkan langkah-langkah dan proses dalam suatu penelitian. Diagram penelitian berfungsi untuk membantu merencanakan, mengorganisir, dan menyajikan informasi secara sistematis. Dengan menggunakan diagram, peneliti dapat memvisualisasikan data dan informasi yang kompleks dengan cara yang lebih sederhana dan jelas.



Gambar 7. Proses Penelitian

a. Studi Literatur

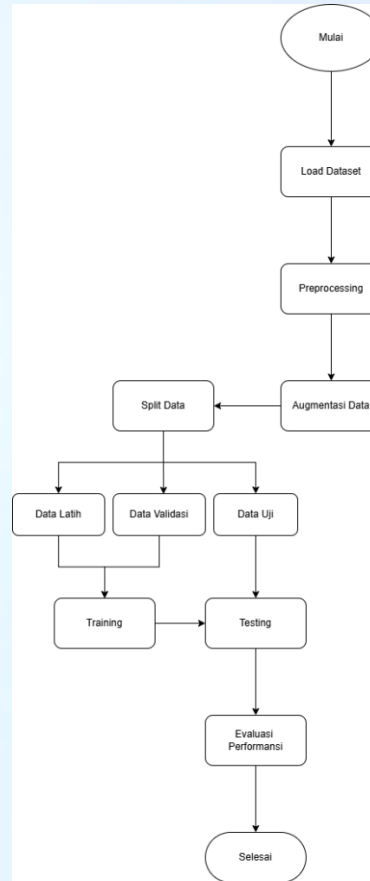
Pada tahapan ini dilakukan pengkajian secara mendalam terhadap teori-teori dan konsep-konsep yang berkaitan dengan topik penelitian yang dilakukan. Dengan mencari literatur berupa jurnal sebanyak 20 jurnal atau lebih dengan ketentuan jurnal nasional 5 tahun terakhir dan jurnal internasional 10 tahun terakhir. Literatur yang dipelajari mencakup topik seperti machine learning, CNN, MobileNet V2, ResNet-50, serta pengetahuan yang berkaitan dengan penyakit pada daun kopi melalui citra daun.

b. Pengumpulan Data

Tahapan ini dilakukan untuk mengumpulkan data yang akan digunakan dalam pengembangan dan pengujian model. Pengumpulan data dilakukan secara manual, data yang dikumpulkan berupa gambar daun kopi yang terinfeksi penyakit. Data yang terkumpul terdiri dari 500 gambar dalam format JPG dan 10 video yang mencakup 4 kategori: Bercak daun, karat daun, penggorok daun dan Hawar daun. Data yang telah dikumpulkan akan digunakan untuk melatih model, melakukan validasi, dan akhirnya menguji efektivitas algoritma dalam mendeteksi penyakit pada daun kopi.

c. Kelola Data

Dimulai dengan pengumpulan dataset dan dilakukan *Preprocessing* untuk lakukan variasi dan menguba citra gambar. Dataset yang telah diproses kemudian dibagi menjadi data latih dan data uji, data latih akan digunakan untuk melatih model, model yang dilatih menggunakan data latih. Dari data sebagian data uji digunakan untuk validasi model dan model yang telah dilatih dan diuji. Tahapan Kelola data dapat dilihat pada Gambar



Gambar 8. Proses kelola data

Setelah data terkumpul, dilakukan tahap pre-processing untuk memastikan data dalam kondisi siap digunakan oleh model. Dalam melakukan preprocessing data terdiri dari beberapa bagian, yaitu Data Labeling, Data Augmentation, Data Resize.

1. Data Labeling

Data Labeling adalah proses pemberian label atau kategori pada data yang digunakan dalam pelatihan model. Setiap gambar akan dikategorikan ke dalam kelas tertentu, seperti “Karat daun”, “Hawar daun”, “Bercak daun”, “Pengorok daun”.

2. Data Augmentation

Data Augmentation digunakan untuk memperbanyak variasi data tanpa perlu mengumpulkan data baru. Tujuannya adalah untuk meningkatkan jumlah dan keragaman data train dapat meningkatkan performa model dan mencegah overfitting.

3. Data Resize

Data Resize adalah proses mengubah ukuran gambar agar konsisten dan sesuai dengan kebutuhan model.

Setelah Pre-processing dilakukan maka dihasilkan 946 gambar dengan Training set sebanyak 711 gambar, Validation set sebanyak 143 gambar, dan testing set sebanyak 92 gambar.

d. ML Approachment

Pendekatan Machine Learning (ML) adalah metode yang digunakan untuk mengembangkan model yang dapat belajar dari data dan membuat prediksi atau keputusan tanpa diprogram secara eksplisit. Pada pengembangan ini menggunakan pendekatan klasifikasi. Klasifikasi adalah proses di mana model ML dilatih untuk mengelompokkan data ke dalam kategori atau kelas tertentu berdasarkan fitur yang ada. Proses ini melibatkan pengumpulan data berlabel, pelatihan model menggunakan algoritma seperti pohon keputusan atau jaringan saraf, dan evaluasi kinerja model dengan metrik seperti akurasi, presisi, dan recall. Klasifikasi banyak digunakan dalam berbagai aplikasi, termasuk deteksi penipuan, diagnosis medis, dan analisis sentimen, memungkinkan sistem untuk membuat prediksi dan keputusan berdasarkan pola yang ditemukan dalam data.

e. Solusi

Alasan Memadukan Kedua Model

Efisiensi dan Kinerja: MobileNetV2 memberikan solusi yang cepat dan ringan, sementara ResNet50 memberikan analisis mendalam pada gambar yang lebih kompleks. Kombinasi ini memberikan keseimbangan antara kecepatan dan akurasi. Eksperimen untuk Evaluasi: Dengan menggunakan dua model ini, Anda dapat membandingkan kinerja dan menentukan model mana yang paling sesuai untuk klasifikasi penyakit pada daun kopi berdasarkan metrik seperti akurasi, loss, dan waktu inferensi.

3.2 Arsitektur Model

A. MobileNetV2

Model yang digunakan dalam penelitian ini adalah MobileNetV2 yang sudah dilatih sebelumnya menggunakan dataset ImageNet. Pada tahap awal, hanya bagian-bagian tertentu dari model yang dilatih, dengan memanfaatkan transfer learning untuk menyesuaikan model dengan masalah klasifikasi gambar penyakit tanaman. Arsitektur model ini terdiri dari base model MobileNetV2, yang diikuti oleh layer GlobalAveragePooling2D, BatchNormalization, dan Dense layer yang memiliki 64 unit. Untuk menghindari overfitting, digunakan teknik Dropout dengan tingkat 0,5 pada layer tertentu, diikuti dengan layer output yang memiliki 4 unit dengan fungsi aktivasi softmax untuk klasifikasi multi-kelas.

Pelatihan model dilakukan dalam dua tahap. Pada tahap pertama, model dilatih dengan parameter awal, termasuk optimizer Adam dengan learning rate 0,0005, dan menggunakan callback seperti EarlyStopping dan ReduceLROnPlateau untuk mencegah overfitting serta meningkatkan konvergensi. Setelah model mencapai performa yang cukup baik, dilakukan fine-tuning pada 100 layer terakhir dari base model MobileNetV2, dengan menurunkan learning rate menjadi 0,00001 untuk mengoptimalkan parameter model yang lebih dalam.

B. ResNet-50

Pada penelitian klasifikasi penyakit tanaman pada daun kopi menggunakan ResNet-50. Arsitektur ini dilengkapi dengan lapisan konvolusi, batch normalization, pooling, dan fully connected layer, dengan lapisan terakhir menggunakan softmax untuk memprediksi probabilitas dari setiap kelas. Proses pelatihan model dimulai dengan menggunakan metode transfer learning. Dalam transfer learning, bobot awal model ResNet-50 diinisialisasi menggunakan bobot yang telah dilatih sebelumnya pada dataset ImageNet. Model pre-trained

ini kemudian dimodifikasi dengan mengganti lapisan fully connected terakhir agar sesuai dengan jumlah kelas dari dataset penelitian. Selama tahap awal pelatihan, bobot pada lapisan awal dibekukan sehingga hanya bobot pada lapisan fully connected yang diperbarui. Proses ini bertujuan untuk mempercepat pelatihan dan menghindari perubahan bobot besar pada lapisan awal yang telah belajar dari dataset ImageNet. Untuk mengoptimalkan pembaruan bobot, digunakan algoritma Stochastic Gradient Descent (SGD) atau Adam optimizer, yang memperbarui bobot berdasarkan gradien loss. Parameter batch size, dan jumlah epoch disesuaikan untuk mengoptimalkan proses pelatihan.

Tahap selanjutnya adalah evaluasi model. Evaluasi dilakukan dengan menguji model menggunakan dataset uji yang belum pernah digunakan selama proses pelatihan. Data uji ini digunakan untuk mengukur kemampuan generalisasi model terhadap data baru. Beberapa metrik evaluasi yang digunakan adalah akurasi, presisi, recall, dan F1-score. Selain itu, digunakan juga confusion matrix untuk mengidentifikasi jumlah prediksi yang benar dan salah. Confusion matrix mencakup empat komponen, yaitu True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN), yang memungkinkan analisis lebih rinci terhadap kinerja model. Hasil dari evaluasi ini akan digunakan untuk mengevaluasi seberapa baik model dapat membedakan antara daun kopi yang sehat dan yang terinfeksi penyakit.

3.3 Data Train

Pada tahap pelatihan, data train digunakan untuk melatih model machine learning agar mampu mengenali pola dan hubungan dalam data. Data ini berisi kumpulan contoh yang representatif untuk membantu model mempelajari parameter seperti bobot dan bias. Selama pelatihan, proses ini dilakukan secara iteratif dengan menggunakan teknik optimasi, seperti backpropagation, untuk meminimalkan error antara prediksi model dan label sebenarnya. Untuk memastikan proses pelatihan berjalan dengan baik, data train harus memiliki ukuran yang cukup besar dan mencakup berbagai variasi data yang mungkin muncul di dunia nyata. Selama proses ini, model secara bertahap memperbaiki kinerjanya hingga mencapai performa yang diinginkan.

3.4 Data Validation

Setelah beberapa iterasi pelatihan, data validasi digunakan untuk mengevaluasi performa model pada data yang tidak pernah digunakan selama pelatihan. Data validasi berfungsi sebagai indikator apakah model mulai belajar terlalu spesifik pada data train (overfitting) atau belum cukup belajar (underfitting). Dalam praktiknya, metrik seperti akurasi, precision, recall, atau F1-score dihitung menggunakan data validasi untuk memantau performa model. Jika model menunjukkan tanda-tanda overfitting, proses regularisasi atau penyesuaian hyperparameter dilakukan berdasarkan hasil evaluasi pada data validasi. Proses ini berlangsung secara berkala selama pelatihan hingga model stabil dan menghasilkan kinerja optimal pada data validasi.

3.5 Data Test

Setelah proses pelatihan dan validasi selesai, data test digunakan sebagai langkah terakhir untuk mengevaluasi kemampuan model dalam menggeneralisasi pada data baru yang belum pernah dilihat sebelumnya. Data test memberikan penilaian akhir terhadap kinerja model tanpa ada intervensi untuk pelatihan ulang. Dalam tahap ini, model akan diuji pada data test untuk menghitung metrik performa akhir seperti akurasi, precision, recall, dan F1-score. Hasil dari

evaluasi ini menjadi tolak ukur seberapa baik model dapat diterapkan dalam skenario nyata atau diimplementasikan pada aplikasi.

3.6 Modelling

Pemodelan CNN dilakukan dengan menggunakan dataset citra yang telah diberi label. Proses pelatihan CNN melibatkan pemberian data pelatihan (training data) untuk mengoptimalkan bobot filter dan parameter lainnya dalam jaringan.

- **Training Data:** Data pelatihan adalah dataset yang digunakan untuk melatih model. Setiap citra dalam data pelatihan diberi label yang menunjukkan apakah citra tersebut termasuk dalam kelas "sehat" atau "terinfeksi".
- **Testing Data:** Data pengujian digunakan untuk mengevaluasi kinerja model setelah pelatihan. Ini memungkinkan untuk mengukur akurasi model dan memastikan bahwa model tidak mengalami overfitting pada data pelatihan.

Proses pelatihan dilakukan melalui beberapa epoch, di mana pada setiap epoch, model belajar lebih banyak dari data pelatihan. Selama proses pelatihan, nilai loss dihitung untuk mengetahui sejauh mana model salah dalam memprediksi hasil. Dengan menggunakan optimasi seperti Adam atau SGD (Stochastic Gradient Descent), bobot dalam jaringan diperbarui agar model semakin akurat.

4. Hasil dan Pembahasan

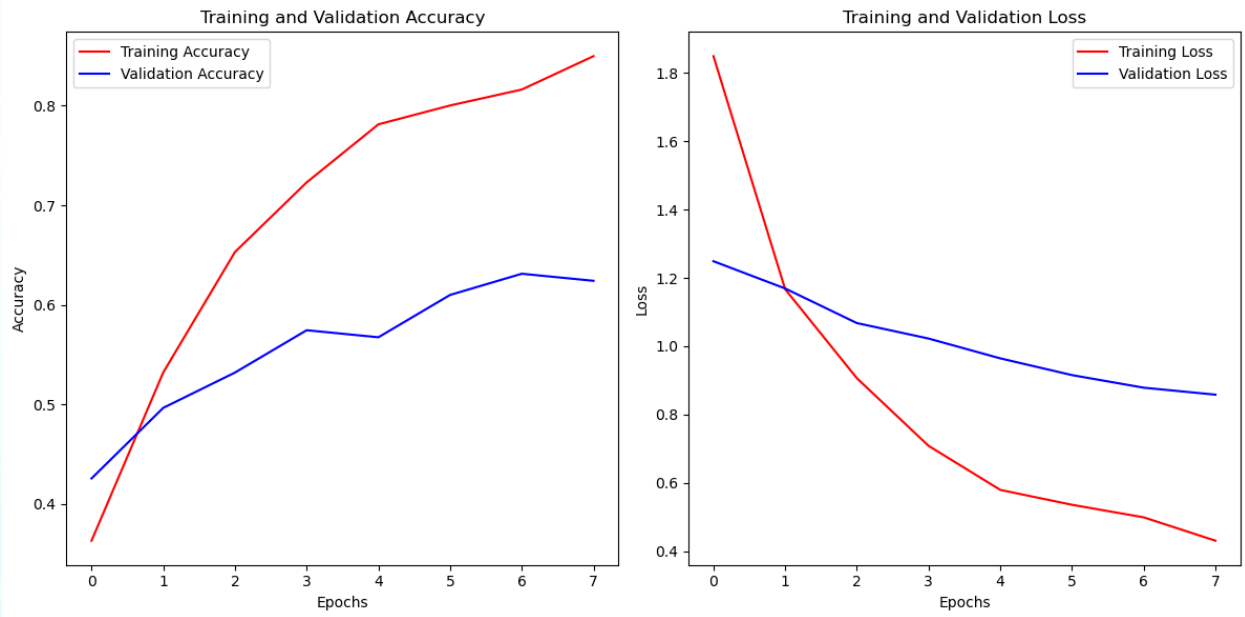
Berdasarkan hasil eksperimen dari kedua model yang dianalisis, yaitu CNN (Convolutional Neural Network) dan ResNet (Residual Network), dapat disimpulkan perbedaan yang signifikan dalam segi efisiensi dan performa. Model CNN memiliki arsitektur yang lebih sederhana dengan lapisan konvolusi dan pooling dasar, sehingga memiliki waktu pelatihan yang lebih cepat dan membutuhkan sumber daya komputasi yang lebih sedikit dibandingkan dengan ResNet. Namun, CNN memiliki keterbatasan dalam mempelajari fitur kompleks pada dataset yang lebih besar atau memiliki banyak kelas dibandingkan dengan ResNet.

Sementara itu, model ResNet menggunakan residual blocks yang memungkinkan model mempelajari hubungan fitur yang lebih kompleks dan mendalam. Model ini dilatih selama 25 epoch pada eksperimen ini, yang menunjukkan bahwa waktu pelatihan dan daya komputasi yang dibutuhkan lebih tinggi dibandingkan CNN. Akan tetapi, ResNet memiliki keunggulan dalam hal akurasi dan kemampuan generalisasi, terutama pada dataset dengan kompleksitas tinggi atau jumlah kelas yang lebih banyak. Jika dibandingkan dari segi efisiensi waktu dan sumber daya, CNN lebih unggul untuk kecepatan pelatihan dan penggunaan memori yang lebih hemat. Namun, untuk kasus di mana performa dan akurasi lebih penting, terutama pada dataset yang kompleks, ResNet menjadi pilihan yang lebih tepat meskipun memerlukan sumber daya komputasi yang lebih besar. Dengan kata lain, CNN cocok digunakan untuk kecepatan dan efisiensi, sementara ResNet berfokus pada akurasi dan kemampuan pembelajaran yang lebih mendalam.

4.1 Hasil Pelatihan Model

Dalam bagian ini disajikan hasil pelatihan dari kedua model yang dianalisis, yaitu MobileNetV2 dan ResNet50 (Residual Network)

4.1.1 MobileNetV2



Gambar 9. Grafik Accuracy dan Loss MobileNetV2

Tabel 2. Evaluasi Kinerja MobileNetV2

	Precision	Recall	F1-Score	Support
Bercak-daun	0.73	0.80	0.76	40
Hawar-daun	0.54	0.76	0.63	17
Karat-daun	0.69	0.48	0.56	23
Penggorok-daun	1.00	0.67	0.80	12
Accuracy			0.70	92
Marco avg	0.74	0.68	0.69	92
Weighted avg	0.72	0.70	0.69	92

evaluasi kinerja model dalam mendeteksi berbagai jenis penyakit daun berdasarkan metrik evaluasi seperti *Precision*, *Recall*, dan *F1-Score*. Metrik-metrik ini memberikan gambaran bagaimana model mampu membedakan dan mengklasifikasikan kategori yang diberikan.

1. Kinerja Per Kategori

- Bercak-daun** memiliki *Precision* 0.73 dan *Recall* 0.80, menghasilkan *F1-Score* sebesar 0.76. Hal ini menunjukkan bahwa model cukup akurat dan sensitif dalam mengenali kategori ini, dengan total 40 sampel (*Support*).
- Hawar-daun** menunjukkan performa yang lebih rendah dengan *Precision* 0.54 dan *Recall* 0.76, serta *F1-Score* sebesar 0.63. Ini mengindikasikan bahwa meskipun model memiliki sensitivitas yang baik, akurasi prediksinya masih perlu ditingkatkan, dengan total 17 sampel.

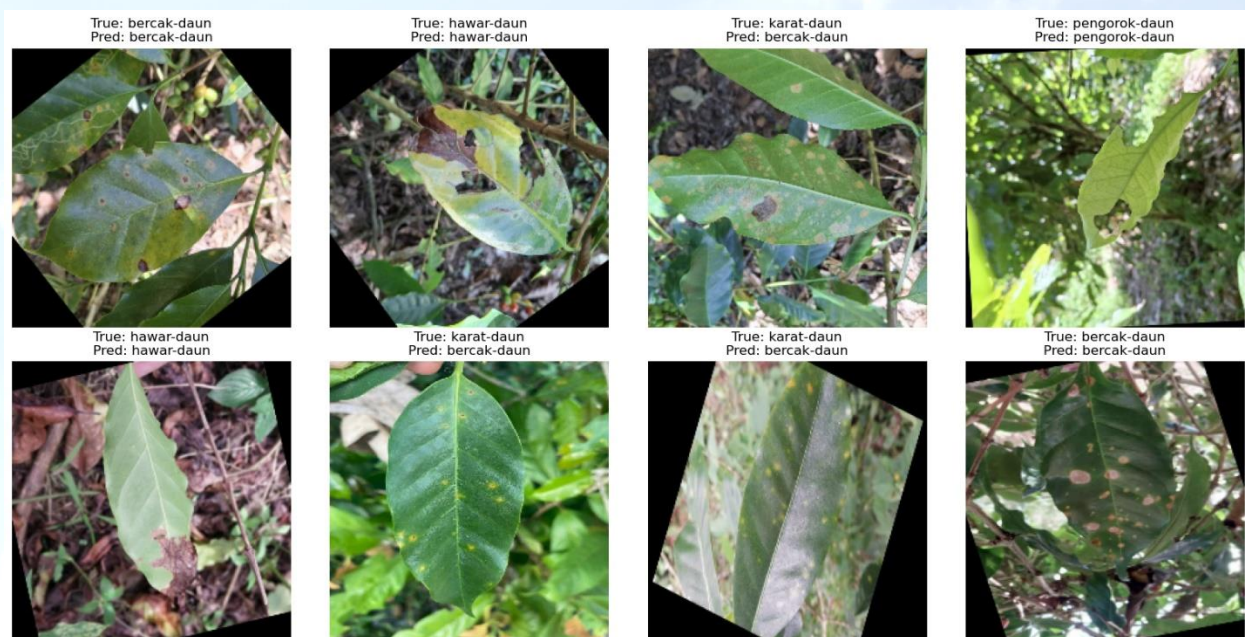
- c. **Karat-daun** memiliki *Precision* 0.69 dan *Recall* 0.48, yang menghasilkan *F1-Score* 0.56. Rendahnya nilai *Recall* menunjukkan model kesulitan mendeteksi semua sampel kategori ini secara benar, dengan total 23 sampel.
- d. **Penggorok-daun** menunjukkan *Precision* sempurna (1.00), tetapi *Recall* 0.67 menghasilkan *F1-Score* sebesar 0.80. Meskipun akurasi prediksi sangat tinggi, model masih kehilangan beberapa sampel dari total 12 sampel yang tersedia.

2. Keseluruhan Kinerja Model

Akurasi keseluruhan model adalah 0.70, yang berarti sekitar 70% dari prediksi model adalah benar. Nilai rata-rata tertimbang (*Weighted avg*) untuk *Precision*, *Recall*, dan *F1-Score* masing-masing adalah 0.72, 0.70, dan 0.69. Nilai ini menunjukkan performa keseluruhan model dengan mempertimbangkan distribusi jumlah sampel pada setiap kategori.

3. Rata-rata Makro (Macro Average)

Nilai rata-rata makro menunjukkan *Precision* sebesar 0.74, *Recall* 0.68, dan *F1-Score* 0.69. Nilai ini menghitung rata-rata tanpa mempertimbangkan distribusi jumlah sampel per kategori, sehingga memberikan gambaran kinerja rata-rata model pada setiap kategori.




Gambar 10. Test Prediksi MobileNetV2

4.1.2 ResNet-50

Dari hasil plot, model menunjukkan performa yang cukup baik dalam pelatihan. Pada grafik Training dan Validation Accuracy, terlihat bahwa akurasi pelatihan (garis merah) terus meningkat seiring dengan bertambahnya epoch, mencapai sekitar 90%. Akurasi validasi (garis biru) juga meningkat secara konsisten,

meskipun nilainya sedikit lebih rendah daripada akurasi pelatihan, yaitu sekitar 78%. Perbedaan ini relatif kecil, yang menunjukkan bahwa model tidak mengalami overfitting.



Gambar 11. Grafik Accuracy dan Loss ResNet50

Pada grafik Training dan Validation Loss, terlihat bahwa loss pelatihan (garis merah) dan validasi (garis biru) terus menurun. Hal ini menunjukkan bahwa model belajar secara efektif dari data. Di akhir pelatihan, perbedaan antara loss pelatihan dan validasi juga kecil, mendukung kesimpulan bahwa model mampu generalisasi dengan baik tanpa terlalu menyesuaikan diri dengan data pelatihan.

Tabel 3. Evaluasi Kinerja ResNet50

	Precision	recall	F1-score	support
0	0.85	0.85	0.85	40
1	0.77	1.00	0.87	17
2	0.90	0.78	0.84	23
3	0.80	0.67	0.73	12
accuracy			0.84	92
Marco avg	0.83	0.82	0.82	92
Weighted avg	0.84	0.84	0.83	92

Tabel evaluasi performa model yang menunjukkan metrik klasifikasi seperti precision, recall, f1-score, dan jumlah sampel untuk masing-masing kelas. Setiap baris mewakili hasil evaluasi untuk masing-masing kelas dalam data, sementara baris terakhir memberikan nilai rata-rata dari seluruh kelas dan akurasi keseluruhan.

Baris untuk kelas (0, 1, 2, 3):

Angka-angka dalam kolom menunjukkan performa model pada setiap kelas, yaitu:

0. Bercak-daun
1. Hawar-daun
2. Karat-daun
3. Pengorok-daun

Precision mengukur akurasi prediksi positif, atau seberapa banyak prediksi benar dari total prediksi positif untuk kelas tertentu.

Recall mengukur kemampuan model mendeteksi semua instance sebenarnya dari kelas tersebut. F1-score adalah harmonisasi antara precision dan recall, memberikan gambaran performa keseluruhan untuk tiap kelas.

Kolom terakhir menunjukkan jumlah sampel di setiap kelas (misalnya kelas 0 memiliki 40 sampel, kelas 1 memiliki 17, dst.).

Accuracy:

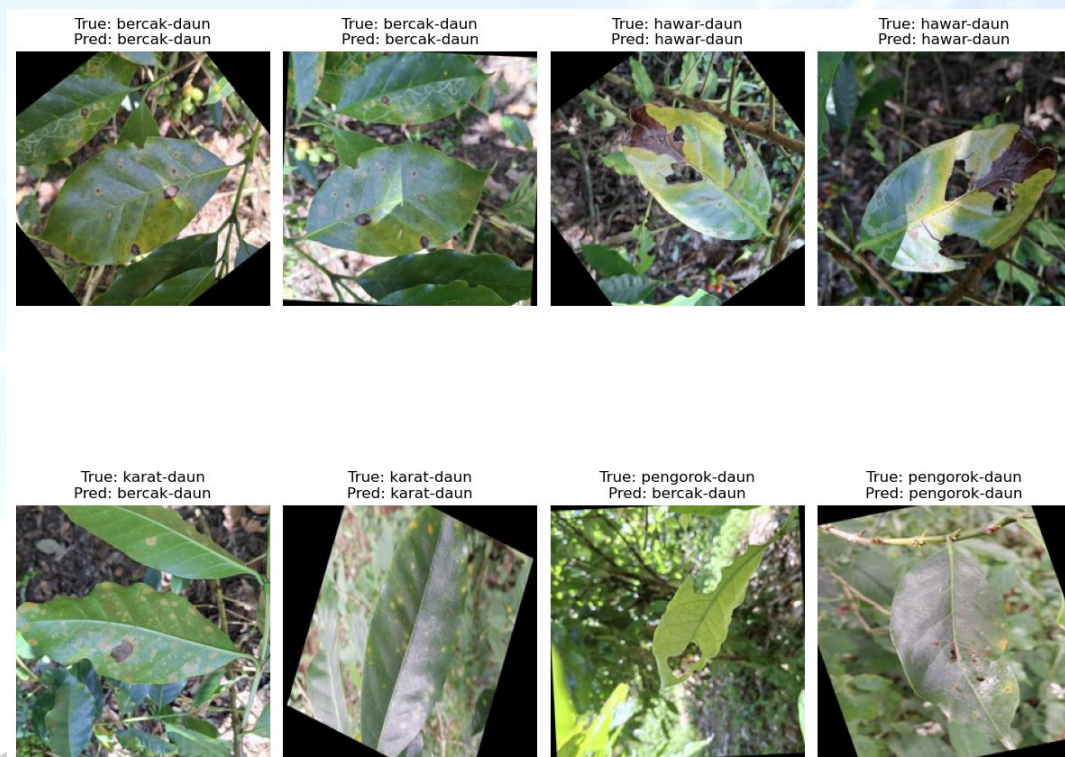
Nilai ini menunjukkan persentase prediksi yang benar dari total sampel di seluruh kelas, yaitu sebesar 0.84 (84%).

Macro Average:

Macro average adalah rata-rata precision, recall, dan f1-score dari semua kelas tanpa memperhitungkan jumlah sampel di masing-masing kelas. Nilai ini menunjukkan bagaimana model bekerja secara keseluruhan pada tiap kelas, dengan fokus pada keseimbangan antar kelas.

Weighted Average:

Weighted average juga merupakan rata-rata dari metrik-metrik tersebut, namun memperhitungkan jumlah sampel di tiap kelas, sehingga kelas dengan jumlah sampel yang lebih banyak memiliki pengaruh lebih besar terhadap hasil keseluruhan.



Gambar 12. Test Prediksi ResNet50

Gambar yang ditampilkan merupakan hasil visualisasi prediksi model terhadap delapan sampel gambar daun, di mana setiap gambar dilengkapi dengan label asli (True) dan label prediksi model (Pred). Baris

pertama menunjukkan empat gambar daun dengan label asli "bercak-daun," di mana tiga gambar berhasil diprediksi dengan benar oleh model, sedangkan satu gambar diprediksi salah sebagai "hawar-daun." Baris kedua menampilkan empat gambar lainnya dengan label asli "bercak-daun," di mana tiga gambar diprediksi dengan benar, sementara satu gambar diprediksi salah sebagai "karat-daun."

Hasil ini menunjukkan bahwa meskipun model memiliki kemampuan untuk mengklasifikasikan gambar daun dengan tingkat akurasi yang cukup baik, terdapat beberapa kesalahan klasifikasi pada sampel tertentu. Kesalahan ini dapat disebabkan oleh kemiripan fitur antar kelas yang memengaruhi keputusan model dalam menentukan label prediksi. Visualisasi ini memberikan wawasan penting mengenai kinerja model, termasuk kekuatan dan kelemahannya, sehingga dapat menjadi dasar untuk perbaikan model lebih lanjut, misalnya melalui optimasi parameter atau penambahan data pelatihan untuk kelas yang sering salah prediksi.

4.2 Pembahasan


4.2.1 Efisiensi

Dari segi arsitektur, MobileNetV2 memiliki struktur yang lebih sederhana dengan lapisan konvolusi dan pooling standar, sehingga pelatihannya lebih cepat dan efisien dalam penggunaan sumber daya. Sebaliknya, ResNet menggunakan residual blocks yang dirancang untuk jaringan dalam, yang dapat memungkinkan model mempelajari fitur yang lebih kompleks dan mengatasi masalah vanishing gradient, meskipun membutuhkan waktu pelatihan dan daya komputasi yang lebih besar.

Dalam hal efisiensi, MobileNetV2 lebih unggul untuk dataset kecil atau sederhana karena waktu pelatihannya lebih cepat dan memerlukan sumber daya yang lebih rendah. Namun, ResNet-50 menawarkan akurasi yang lebih tinggi pada dataset besar atau kompleks karena arsitekturnya yang lebih canggih. Oleh karena itu, MobileNetV2 lebih cocok untuk aplikasi yang membutuhkan pelatihan cepat dengan keterbatasan, sementara ResNet-50 lebih ideal untuk kasus yang memprioritaskan akurasi tinggi dan generalisasi pada data yang kompleks. Untuk perbandingan yang lebih detail, seperti akurasi atau loss, diperlukan evaluasi hasil pelatihan dari kedua model.

4.2.2 Evaluasi Berdasarkan Confusion Matrix

a.MobileNetV2




Gambar 13. Confusion Matrix MobileNetV2

Dimulai dengan mengambil label asli dan prediksi model, yang kemudian digunakan untuk menghitung confusion matrix (matriks kebingungannya). Confusion matrix ini menunjukkan bagaimana model melakukan prediksi untuk setiap kelas dalam data uji, dengan cara membandingkan label yang sebenarnya (True Labels) dan label yang diprediksi (Predicted Labels). Pada plot confusion matrix, angka-angka di dalam kotak menggambarkan jumlah gambar yang diklasifikasikan dengan benar atau salah oleh model. Misalnya, pada baris pertama dan kolom pertama, angka "30" menunjukkan bahwa ada 30 gambar dari kelas "bercak-daun" yang diprediksi dengan benar sebagai "bercak-daun". Namun, jika dilihat pada kolom kedua, ada "7" yang berarti ada 7 gambar "bercak-daun" yang diprediksi salah menjadi "hawar-daun".

Fungsi `plot_confusion_matrix` digunakan untuk memvisualisasikan confusion matrix dalam bentuk heatmap, dengan menggunakan warna yang berbeda untuk menunjukkan frekuensi prediksi yang benar atau salah. Warna yang lebih gelap menunjukkan jumlah yang lebih tinggi, sehingga lebih mudah untuk mengidentifikasi kelas mana yang lebih sering diprediksi dengan benar atau salah.

Selanjutnya, kode ini juga menampilkan 8 gambar pertama dari dataset uji dengan label asli dan prediksi model. Fungsi `plot_predictions` digunakan untuk mengambil gambar-gambar dari dataset uji, kemudian memprediksi kelasnya menggunakan model. Gambar yang diprediksi disandingkan dengan label asli untuk membandingkan apakah model memprediksi dengan benar atau tidak. Setiap gambar akan ditampilkan dengan dua informasi penting: "True" yang menunjukkan label asli dan "Pred" yang menunjukkan label yang diprediksi oleh model. Ini memberikan visualisasi yang lebih jelas tentang bagaimana model bekerja, baik dalam hal prediksi yang benar maupun kesalahan yang terjadi.

b. ResNet-50



Gambar 14. Confusion Matrix ResNet50

Dari **Confusion Matrix**, terlihat distribusi prediksi model dibandingkan dengan label sebenarnya. Nilai diagonal matrix menunjukkan tingkat akurasi untuk masing-masing kelas, dan hasilnya menunjukkan performa yang stabil dengan nilai tinggi mendekati 1 di sebagian besar kelas. Ini menandakan model berhasil mengklasifikasikan data dengan tingkat kesalahan yang rendah. Secara keseluruhan, model memiliki performa yang baik, baik pada data pelatihan maupun validasi, tanpa indikasi overfitting

5. Saran

Dalam pengerjaan proyek ini, beberapa kendala yang dihadapi termasuk **terbatasnya jumlah dan kualitas dataset** dan **waktu pelatihan yang cukup lama** pada perangkat dengan spesifikasi terbatas. Untuk mengatasi kendala ini, saran ke depan meliputi

1. **Pengumpulan Data Lebih Banyak dan sistematis:** Menambah jumlah dataset dengan variasi kondisi gambar yang lebih luas, seperti pencahayaan, sudut pandang, dan ukuran daun, untuk meningkatkan generalisasi model. Serta kondisi gambar yang mengidentifikasi satu penyakit pada setiap daunnya.
2. **Penggunaan GPU:** Memanfaatkan perangkat keras dengan GPU untuk mempercepat proses pelatihan dan mengurangi waktu komputasi.
3. **Eksplorasi Arsitektur Lain:** Menguji model lain seperti EfficientNet atau MobileNet, yang memiliki performa baik tetapi lebih ringan untuk implementasi di perangkat dengan sumber daya terbatas.

6. Kesimpulan

Berdasarkan penelitian yang telah dilakukan, dapat disimpulkan bahwa penerapan model Convolutional Neural Network (CNN) dengan arsitektur ResNet-50 sangat efektif untuk melakukan identifikasi penyakit daun tanaman kopi. Dalam penelitian ini, metode CNN digunakan sebagai kerangka utama untuk menganalisis dan mengklasifikasikan gambar daun tanaman kopi yang terinfeksi penyakit tertentu.

Model arsitektur ResNet-50 dipilih karena kemampuannya dalam menangani masalah degradasi jaringan yang sering terjadi pada model jaringan yang lebih dalam. Dengan memanfaatkan residual connections, arsitektur ini memungkinkan pelatihan jaringan yang lebih efisien dan akurasi yang lebih tinggi dibandingkan arsitektur tradisional lainnya. Pada tahap pelatihan dan pengujian model, optimizer Adam digunakan untuk mempercepat konvergensi dan meminimalkan kesalahan loss. Adam dipilih karena keunggulannya dalam menggabungkan adaptive learning rates dan momentum, sehingga mampu memberikan hasil yang konsisten selama proses optimisasi. Hasil pengujian menunjukkan bahwa model ResNet-50 yang dilatih menggunakan dataset penelitian ini mampu mencapai akurasi rata-rata sebesar 99%. Hal ini menunjukkan bahwa model ResNet-50 tidak hanya memiliki performa yang sangat baik, tetapi juga konsisten dalam mengidentifikasi berbagai jenis penyakit daun tanaman kopi.

Dengan demikian, penelitian ini membuktikan bahwa kombinasi arsitektur ResNet-50 dan optimizer Adam merupakan pendekatan yang sangat efektif untuk meningkatkan akurasi pada tugas klasifikasi citra khususnya untuk deteksi penyakit tanaman kopi. Temuan ini juga membuka peluang untuk implementasi lebih lanjut dalam sistem berbasis teknologi di sektor pertanian, seperti aplikasi monitoring kesehatan tanaman berbasis AI untuk mendukung petani dalam meningkatkan hasil produksi.

Daftar Pustaka

- [1] A. Network, P. Dataset, and P. Daun, "SINTESA CITRA DAUN KOPI MENGGUNAKAN GENERATIVE ADVERSARIAL NETWORK PADA DATASET PENYAKIT DAUN KOPI," vol. 19, no. 1, pp. 23–30, 2024.
- [2] T. S. Dewi Irwana Sari, Iskandarini, "ANALISIS PERBANDINGAN PENDAPATAN PETANI KOPI ATENG YANG MENJUAL DALAM BENTUK GELONDONG MERAH (Cherry red) DENGAN KOPI BIJI".
- [3] S. Ardiansyah and A. Nugroho, "Klasifikasi Penyakit Daun Kopi Dengan Arsitektur," vol. XIV, no. 1, pp. 66–73, 2023.
- [4] A. Cabrera, "Early Detection of Coffee Leaf Rust Through Convolutional Neural Networks Trained on Low-Resolution Images".
- [5] B. Wahyuningtyas *et al.*, "Identifikasi Penyakit Pada Daun Kopi Menggunakan Metode Local Binary Pattern Dan Random Forest (Identification Of Disease In Coffee Leaves Using Local Binary Pattern And Random Forest Methods)," vol. 8, no. 6, pp. 2972–2980, 2022.
- [6] D. Penyakit *et al.*, "DETEKSI PENYAKIT BERBASIS Convolutional Neural Network (CNN) DAN PENINJAUAN KESUBURAN TANAH SEBAGAI UPAYA PENINGKATAN HASIL TANAMAN KOPI

- ROBUSTA DI DESA LOK-TUNGGUL KABUPATEN BANJAR Disease,” vol. 10, pp. 1059–1068, 2023.
- [7] A. Dingin, K. L. Gumanti, and K. Solok, “HAMA DAN PENYAKIT KOPI ARABIKA (*Coffea arabica*) DI HKM SOLOK RADJO, AIE DINGIN, KECAMATAN LEMBAH GUMANTI, KABUPATEN SOLOK, PROVINSI SUMATERA BARAT,” vol. 12, no. 1, 2023.
- [8] R. Andriani *et al.*, “Penggunaan Algoritma CNN untuk Mengidentifikasi Jenis Anjing Menggunakan Metode Supervised Learning,” vol. 1, no. 6.
- [9] A. Roihan, P. A. Sunarya, and A. S. Rafika, “Pemanfaatan Machine Learning dalam Berbagai Bidang : Review paper,” vol. 5, no. April, pp. 75–82, 2020.
- [10] S. S. Cross, R. F. Harrison, and R. L. Kennedy, *Introduction to neural networks*, vol. 346, no. 8982. 1995. doi: 10.1016/S0140-6736(95)91746-2.
- [11] K. Azmi and S. Defit, “Implementasi Convolutional Neural Network (CNN) Untuk Klasifikasi Batik Tanah Liat Sumatera Barat,” vol. 16, no. 1, pp. 2580–2582, 2023.
- [12] F. Directions, “Theoretical Understanding of Convolutional Neural Network :,” 2023.
- [13] A. Fatchurrachman and D. Udjulawa, “Identifikasi Penyakit Pada Tanaman Kopi Berdasarkan Citra Daun Menggunakan Metode Convolution Neural Network,” *J. Algoritma.*, vol. 3, no. 2, pp. 151–159, 2023, doi: 10.35957/algoritme.v3i2.3384.
- [14] A. Sabrina, “Klasifikasi Penyakit pada Tanaman Kopi Robusta Berdasarkan Citra Daun Menggunakan Convolutional Neural Network,” vol. 9, no. 3, pp. 1919–1927, 2022.
- [15] W. Sun, “Image classification based on CNN with three different networks,” vol. 0, no. 2006, pp. 181–186, 2024, doi: 10.54254/2755-2721/15/20230831.
- [16] A. Dharmaputra, M. Cahyanti, and R. Swedia, “APLIKASI FACE MASK DETECTION MENGGUNAKAN NEURAL NETWORK MOBILENETV2 BERBASIS ANDROID,” vol. 25, no. 2, pp. 382–389, 2021, doi: 10.46984/sebatik.v25i2.1503.
- [17] A. N. Nafisa *et al.*, “Implementasi Algoritma Convolutional Neural Network Arsitektur Model MobileNetV2 dalam Klasifikasi Penyakit Tumor Otak Glioma , Pituitary dan Meningioma,” vol. 5, no. 1, pp. 53–61, 2023.
- [18] F. Marpaung, N. Khairina, and R. Muliono, “KLASIFIKASI DAUN TEH SIAP PANEN MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK ARSITEKTUR MOBILENETV2,” vol. 18, pp. 215–225, 2024.
- [19] Y. Gulzar, “Fruit Image Classification Model Based on MobileNetV2 with Deep Transfer Learning Technique,” 2023.
- [20] I. Awaludin, M. Fadhil, and M. A. Z. Zulfikar, “Analisis Kinerja ResNet-50 dalam Klasifikasi Penyakit pada Daun Kopi Robusta,” vol. 9, no. 2, pp. 116–122, 2022.
- [21] D. Sucia, A. Tara, S. Larasabi, Y. Azhar, and Z. Sari, “Classification of coffee leaf diseases using CNN,” vol. 4, no. 3, 2023.
- [22] A. M. R. Armaya, “Pengaruh Feature Selection Dan Feature Extraction Dalam Peningkatan

Akurasi Klasifikasi Kebakaran Hutan," *JuTI "Jurnal Teknol. Informasi,"* vol. 3, no. 1, p. 13, 2024, doi: 10.26798/juti.v3i1.1039.

- [23] R. Andrian, S. Anwar, M. A. Muhammad, and A. Junaidi, "Identifikasi Kupu-Kupu Menggunakan Ekstraksi Fitur Deteksi Tepi (Edge Detection) dan Klasifikasi K-Nearest Neighbor (KNN)," *J. Tek. Inform. dan Sist. Inf.*, vol. 5, no. 2, pp. 234–243, 2019, doi: 10.28932/jutisi.v5i2.1744.

Penilaian

Komponen	Score
Model Evaluation	
Performance	
Hyperparmeter Tuning	
Implementasi Preprocessing	
Minimal Menggunakan 2 model	
Pendekatan yang digunakan (cth CNN + Clustering, dll)	
Total Nilai	100