

Arsitektur *Convolutional Neural Network* (CNN) Alexnet Untuk Klasifikasi Hama Pada Citra Daun Tanaman Kopi

Dicki Irfansyah^{1*)}, Metty Mustikasari², Amat Suroso³

^{1,2}Jurusan Sistem Informasi Bisnis, Fakultas Ilmu Komputer dan Teknologi Informasi, Universitas Gunadarma, Jakarta

³Jurusan Sistem Informasi, STMIK Bani Saleh, Bekasi

^{1,2}Jln. Margonda Raya No.100, Beji Depok

³Jln. M. Hasibuan No. 68, Bekasi

email: ¹a.irfan.id@gmail.com, ²metty@staff.gunadarma.ac.id, ³ahmad_suroso04@yahoo.com

Abstract — Indonesia is the fourth largest coffee producing country in the world. However, when compared to 3 other countries, Indonesia's coffee production is still relatively small. Many factors cause this to happen, including the number of farmers' coffee trees that are attacked by diseases. If the handling of this disease is slow, then the disease in one tree can be transmitted to other trees. This causes a decrease in Indonesian coffee productivity. In this study, the author implemented the Alexnet Convolutional Neural Network (CNN) architecture using the MATLAB programming platform for the identification of diseases in coffee plants through images. The total number of datasets used is 300 data which is divided into 3 classes, namely health, rust and red spider mite. The training process involving 260 training data resulted in an accuracy of 69.44-80.56%. The network testing process using 40 test data resulted in an accuracy of 81.6%. Based on the results of the study, it can be said that the Alexnet architecture is accurate for the classification of leaf pests on coffee plants.

Abstrak – Indonesia adalah negara penghasil kopi terbesar keempat di dunia. Namun jika dibandingkan dengan 3 negara lainnya, hasil produksi kopi Indonesia masih terbilang kecil. Banyak faktor yang membuat hal ini terus berlanjut, diantaranya adalah banyak pohon kopi petani yang terserang penyakit. Jika penanganan terhadap penyakit ini lambat, maka penyakit pada satu pohon dapat menular pada pohon lainnya. Hal ini menyebabkan turunnya produktivitas kopi Indonesia. Pada penelitian ini penulis mengimplementasikan arsitektur *Convolutional Neural Network* (CNN) Alexnet dengan platform pemrograman MATLAB untuk identifikasi penyakit pada tanaman kopi melalui citra. Jumlah total *dataset* yang digunakan sebanyak 300 data yang terbagi dalam 3 kelas yaitu *health*, *rust* dan *red spider mite*. Proses *training* yang melibatkan 260 data latih menghasilkan akurasi dengan nilai 69.44-80.56%. Proses pengujian jaringan menggunakan 40 data uji menghasilkan akurasi sebesar 81.6%. Berdasarkan hasil penelitian dapat dikatakan bahwa arsitektur Alexnet akurat untuk klasifikasi hama daun pada tanaman kopi.

Kata Kunci – Klasifikasi Citra, MATLAB, *Convolutional Neural Network*, Arsitektur Alexnet, Tanaman Kopi.

I. PENDAHULUAN

Indonesia baru mampu memasok sebesar 4% untuk pemenuhan kebutuhan kopi Uni Eropa, hal ini sangat disayangkan padahal market yang tersedia amatlah besar. Menurut peneliti bidang pangan dari Center for Indonesia Policy Studies (CIPS), setidaknya ada dua hal yang menjadi

***) penulis korespondensi:** Dicky Irfansyah
Email: a.irfan.id@gmail.com

penyebab kurangnya produktivitas kopi di Indonesia. Pertama karena pohon pada usia yang sudah tua akan sangat rentan terhadap serangan penyakit, kemudian kedua karena peremajaan tanaman yang masih belum dilakukan dengan baik.

Penelitian ini bertujuan untuk mengembangkan sebuah program dengan platform pemrograman MATLAB. Program ini menggunakan arsitektur CNN Alexnet untuk klasifikasi penyakit daun pada tanaman kopi. Uji coba dilakukan guna mengetahui akurasi dari arsitektur CNN Alexnet dalam klasifikasi penyakit pada daun tanaman kopi.

Klasifikasi adalah proses untuk membangun suatu model atau fungsi yang menggambarkan konsep suatu data. Pada proses klasifikasi sejumlah data dikumpulkan kemudian dibagi menjadi kategori-kategori tertentu yang disebut *class*. *Class* yang terbentuk disebut *dataset* pelatihan, data akan dipelajari oleh algoritma klasifikasi. Proses ini disebut pelatihan/*training*. Pelatihan akan menghasilkan model yang dapat mengklasifikasi data baru.


Convolutional Neural Network (CNN) merupakan variasi dari *Multi layer perception* (MLP) yang memiliki sedikit parameter bebas karena tidak memerlukan *pre-processing*, segmentasi, dan ekstraksi fitur. Model ini dapat mengurangi sejumlah parameter bebas dan dapat menangani deformasi gambar *input* seperti translasi, rotasi dan skala [1].

Aktivitas pelatihan pada CNN melibatkan 4 parameter yang nilainya dapat diubah-ubah yaitu *epoch*, *mini-batch*, *Learning rate* dan *momentum*. Pada proses pelatihan semua *dataset* melewati satu proses *forward* dan *backward* dimana nilai bobot diubah hingga menjadi konvergen, siklus ini dinamakan dengan *epoch*[2]. *Mini-Batch* merupakan variasi dari *batch* yang mengambil nilai rata-rata *loss* dan mereduksi variasi *update* parameter agar konvergensi lebih stabil dan mengoptimalkan penggunaan memori sehingga lebih efisien [3]. *Learning rate* mempengaruhi waktu pencapaian target, dimana secara perlahan akan mengoptimalkan perubahan nilai *weight* dan menghasilkan *loss* yang lebih kecil. *Learning rate* merupakan nilai konstan antara 0 dan 1. Tidak adanya nilai yang pasti ini menyebabkan dibutuhkan pengalaman praktis agar diperoleh hasil yang maksimal[4]. Metode *momentum* dirancang untuk mempercepat pembelajaran, terutama dalam menghadapi gradien kelengkungan tinggi [5].

Alexnet merupakan salah satu arsitektur CNN yang mendapatkan gelar juara pada kompetisi *ImageNet Large Scale Visual Recognition Challenge* (ILSVRC) yang merupakan kompetisi *image classification* dengan skala besar

pada tahun 2012. AlexNet menjadi suatu terobosan baru pada deep learning dengan menerapkan ConvsNet yang dipadukan dengan teknik *Dropout Regularization*, pemanfaatan ReLu sebagai fungsi aktivasi dan data augmentation. Alexnet dirancang untuk dapat melakukan klasifikasi dengan 1000 kategori [6].

Arsitektur Alexnet terdiri atas 5 *convolution layer*, 3 *pooling layer*, 2 *dropout layer*, dan 3 *fully connected layer* [7]. Konvolusi adalah suatu istilah matematis yang berarti mengaplikasikan sebuah fungsi pada *output* fungsi lain secara berulang dan menghasilkan *feature map*. Fungsi dari konvolusi sendiri adalah untuk ekstraksi fitur citra [8]. *Pooling* atau *subsampling* adalah pengurangan ukuran matriks. Terdapat dua macam *pooling* yang sering digunakan yaitu *average pooling* dan *max pooling* [9]. *Dropout* adalah cara yang dipakai untuk mengurangi *overfitting* pada *neural network*, hal ini dilakukan dengan mencegah adaptasi berlebihan pada data pelatihan. *Fully connected layer* merupakan kumpulan proses konvolusi [10]. Arsitektur Alexnet dapat dilihat pada Gbr. 1 dan detail layer alexnet dapat dilihat pada Tabel I.



Gbr. 1 Arsitektur alexnet.

TABEL I
DETAIL ARSITEKTUR ALEXNET

Layer	Feature Map	Size	Kernel Size	Stride	Activation
Input	1	227x227x3	-	-	-
Convolution 1	96	55x55x96	11x11	4	relu
Pooling 1	96	27x27x96	3x3	2	relu
Convolution 2	256	27x27x256	5x5	1	relu
Pooling 2	256	13x13x256	3x3	2	relu
Convolution 3	384	13x13x384	3x3	1	relu
Convolution 4	384	13x13x384	3x3	1	relu
Convolution 5	256	13x13x256	3x3	1	relu
Pooling 3	256	6x6x256	3x3	2	relu
Fully connected 1	-	9216	-	-	relu
Fully connected 2	-	4096	-	-	relu
Fully connected 3	-	4096	-	-	relu
Out put	-	1000	-	-	Softmax

Penelitian ini menggunakan *platform* pemrograman MATLAB. *Matrix Laboratory* atau disingkat MATLAB merupakan sebuah platform pemrograman untuk komputasi numerikal yang dikembangkan oleh The MathWorks.inc. MATLAB mampu melakukan operasi manipulasi matriks, *plotting* fungsi dengan data, penerapan algoritma dan pembuatan *Graphical User Interface* (GUI) [11]. MATLAB memiliki *toolbox* untuk berbagai keperluan seperti Simulink, *Neural Network*, *Fuzzy Logic Toolbox* dan lain sebagainya.

Jaringan yang terbentuk akan dievaluasi menggunakan *confusion matrix*. *Confusion matrix* adalah alat yang berguna untuk menganalisis seberapa baik *classifier/model* mengenali tuple dari kelas yang berbeda [12]. Terdapat 4 istilah sebagai representasi hasil proses klasifikasi pada *confusion matrix*. Keempat istilah tersebut adalah *True Positive* (TP) merupakan data positif yang diprediksi benar, *True Negative* (TN) merupakan data negatif yang diprediksi benar, *False*

Positive (FP) merupakan data negatif namun diprediksi sebagai data positif dan *False Negative* (FN) merupakan data positif namun diprediksi sebagai data negatif.

Hasil penelitian ini diharapkan dapat digunakan tenaga ahli maupun pihak terkait lain untuk membantu petani kopi di Indonesia dalam mengidentifikasi penyakit pada tanaman kopi. Dengan deteksi dini diharapkan penanganan terhadap hama daun tanaman kopi dapat lebih efektif dan efisien sehingga tanaman kopi dapat menghasilkan buah dengan maksimal serta dapat menaikkan hasil produksi kopi.

II. PENELITIAN YANG TERKAIT

Penelitian terkait yang pernah dilakukan sebelumnya diantaranya :

Implementasi K-Nearest Neighbor untuk Klasifikasi Bunga dengan Ekstraksi Fitur Warna RGB oleh Lia Farokhah [13]. Penelitian ini bertujuan untuk membuktikan kelemahan algoritma KNN dan ekstraksi fitur RGB pada karakteristik citra tertentu. Data yang diujikan dibagi menjadi dua kelompok. *Dataset* pertama adalah berisi citra yang memiliki kesamaan bentuk namun berbeda dari segi warna. Sedangkan *dataset* kedua berisi citra yang berbeda secara bentuk namun memiliki karakter warna yang sama. Jumlah total *dataset* yang digunakan sebanyak 360 data. Pada nilai K=1 akurasi yang dihasilkan sebesar 50-60% dan pada nilai K=5 akurasi yang dihasilkan sebesar 90-100%.

Klasifikasi Penyakit Noda pada Citra Daun Tebu Berdasarkan Ciri Tekstur dan Warna Menggunakan *Segmentation-Based Gray Level Cooccurrence Matrix* dan *LAB Color Moments* oleh Ratnasari, Ginardi dan Fatchah [14]. Pada penelitian ini dilakukan proses ekstraksi ciri pada citra *input* yang menghasilkan 12 fitur warna dan 24 fitur tekstur. Hasil dari ekstraksi ciri tersebut akan dipakai sebagai *input* algoritma KNN. Jenis penyakit yang diklasifikasi ada 3 (tiga) yaitu noda cincin, noda karat, dan noda kuning. Akurasi tertinggi yang dapat dicapai sebesar 93%.

Deteksi Hama Pada Daun Teh Dengan Metode *Convolutional Neural Network* (CNN) oleh Hidayat dan Hermawan [15]. Tahapan pertama penelitian ini adalah *preprocessing* dengan metode *grayscale*, *edge detection* (Sobel) dan *Standardization*. Tahap kedua adalah feedforward menggunakan metode *convolutinal layer*, *relu*, *max pooling* dan *fully connected layer*. Tahap ketiga adalah *backpropagation* dan tahap keempat adalah *confusion matrix*. Hama yang diteliti adalah *blister blight* dan *helloweltis* dengan jumlah total *dataset* sebanyak 440 citra dimana 400 data digunakan sebagai data *training* dan 40 data citra digunakan sebagai data *testing*. Nilai rata-rata akurasi yang dicapai sebesar 95% pada nilai *epoch* 20.

Implementasi Metode *Convolutional Neural Network* Untuk Klasifikasi Tanaman pada Citra Resolusi Tinggi oleh Arrofiqoh dan Harintaka [16]. Penelitian ini menggunakan pendekatan klasifikasi semantik otomatis yang mampu mengenali jenis tumbuhan dengan menggunakan algoritma *Convolutional Neural Network* (CNN). Data citra diambil menggunakan teknologi UAV (*Unmanned Aerial Vehicle*). Jenis tanaman yang diteliti adalah padi, bawang merah, kelapa, pisang, dan cabai. Jumlah total *dataset* yang digunakan sebanyak 500 citra yang dibagi menjadi 3 bagian. Akurasi yang dicapai pada proses *training* sebesar 100%.

Pengujian menggunakan data validasi dapat mencapai akurasi sebesar 93% dan akurasi terhadap data *testing* mencapai 82%.

Autentikasi Daun Herbal Menggunakan *Convolutional Neural Network* dan Raspberry Pi oleh Haryono, Anam dan Saleh[17]. Penelitian ini mengimplementasikan algoritma *Convolutional Neural Network* (CNN) pada Raspberry Pi untuk identifikasi tanaman herbal melalui citra daun. Jenis daun tanaman herbal yang diteliti adalah binahong, jambu, kunyit, laos, mengkudu, pegagan dan salam. Jumlah total *dataset* yang digunakan sebanyak 3.150 data. Sebanyak 2.100 data digunakan untuk *training* dan 1.050 data digunakan untuk *testing*. Pada proses *training* akurasi yang dihasilkan mencapai 94.45%. Pada proses *offline testing* akurasi yang dihasilkan mencapai 93.62%, sedangkan pada *live testing* akurasi yang dihasilkan mencapai 91.04%.

III. METODE PENELITIAN

Penelitian ini mengembangkan sebuah program menggunakan platform pemrograman MATLAB. Program yang dikembangkan akan mengimplementasikan algoritma CNN dengan arsitektur Alexnet yang dapat bekerja secara offline tanpa perlu terhubung pada jaringan internet.

Program ini terdiri atas 3 halaman. Halaman utama merupakan halaman yang akan tampil pertama kali saat program dijalankan. Halaman pelatihan merupakan halaman dimana *user* dapat melakukan serangkaian proses pelatihan hingga proses validasi serta mendapatkan nilai akurasi dari jaringan yang terbentuk terhadap data validasi. Nilai akurasi dianggap baik jika nilainya > 70%. Halaman pengolahan citra merupakan halaman dimana *user* dapat melakukan serangkaian proses klasifikasi, mulai dari *input* data citra hingga mendapatkan hasil klasifikasi citra tersebut.

3.1 Analisa Data

Secara spesifik bagian tanaman yang digunakan pada penelitian ini adalah daun tanaman kopi. Beberapa hama yang menyerang tanaman kopi akan menyebabkan perubahan fisik pada daun tanaman kopi. Dengan demikian klasifikasi dapat diimplementasikan untuk identifikasi penyakit atau hama tersebut.

Dataset yang digunakan pada penelitian ini adalah RoCoLe: *A robusta coffee leaf images dataset*. *Dataset* dapat diunduh di <https://data.mendeley.com/datasets/c5yvn32dzg/2>. Kelas yang diambil adalah *health* (Gbr. 4), *red spider mite* (Gbr. 5) dan *rust* (Gbr. 6). Kelas *health* mewakili daun tanaman kopi dalam kondisi sehat, kelas *rust* dan *red spider mite* mewakili daun tanaman kopi yang terserang hama atau penyakit.



Gbr. 4 Health



Gbr. 5 Red spider mite




Gbr. 6 Rust.

3.2 Perancangan

A. Struktur Program Secara Umum

Struktur program ini terdiri atas 3 halaman dapat dilihat pada Gbr. 7




Gbr.7 Struktur program secara umum.

B. Proses Pelatihan

Proses pelatihan meliputi *input* data latih, pembagian data latih dan data validasi, setting parameter, *training* dan validasi. Nilai akurasi *training* dan validasi akan dihitung dengan menggunakan persamaan (1).

$$\text{Akurasi} = \frac{\text{Jumlah benar}}{\text{Total data}} \times 100 \quad (1)$$

Proses ini diimplementasi pada halaman pelatihan. *Flowchart* proses pelatihan dapat dilihat pada Gbr. 8



Gbr. 8 Flowchart proses pelatihan.

Detail kebutuhan *input* dan output proses pelatihan dapat dilihat pada Tabel II.

TABEL II
KEBUTUHAN INPUT OUTPUT PROSES PELATIHAN


Kebutuhan input	Kebutuhan output
Data latih	Detail data latih (nama file, kelas aktual dan keluaran)
Epoch	Detail data validasi (nama file, kelas aktual dan keluaran)
Mini-batch	Akurasi
Learning rate	Jaringan/model
Momentum	

TABEL III
PEMBAGIAN DATASET

No	Kelas	Jumlah Data Latih	Jumlah Data Uji
1	health	80	20
2	rust	80	20
3	red_spider_mite	80	20
	Total	240	60

C. Proses Klasifikasi

Pada proses klasifikasi, *user* akan menggunakan jaringan yang didapatkan dari proses pelatihan. *Input* berupa citra akan diklasifikasi oleh jaringan sehingga didapatkan termasuk kelas manakah citra tersebut. Proses ini diimplementasi pada halaman pengolahan citra. *Flowchart* proses klasifikasi ditunjukkan Gbr. 9



Gbr. 9 Flowchart proses klasifikasi.

3.3 Pengujian

Pengujian dilakukan menggunakan *confusion matrix* untuk mendapatkan nilai *accuracy*, *precision* dan *recall*. Gambar confusion matrix ditunjukkan pada Gbr. 10

		Predicted class		
		yes	no	Total
Actual class	yes	TP	FN	P
	no	FP	TN	N
Total		P'	N'	P + N

Gbr. 10 Confusion matrix.

Nilai *accuracy* dihitung dengan persamaan (1), *precision* dengan persamaan (2) dan *recall* dengan persamaan (3).

$$Accuracy = \frac{TP + TN}{P + N} \quad (2)$$

$$Precision = \frac{TP}{TP + FP} \quad (3)$$

$$Recall = \frac{TP}{P} \quad (4)$$

IV. HASIL DAN PEMBAHASAN

4.1 Pembagian dataset

Supaya jumlah *dataset* masing-masing kelas sama banyak maka diseleksi sebanyak 100 citra yang sesuai dengan kebutuhan penelitian untuk masing-masing kelas. Kriteria data yang akan digunakan adalah citra dengan fokus yang baik pada objek utama dan citra tanpa objek lain. Pembagian *dataset* dapat dilihat pada Tabel III.

4.2 Halaman utama

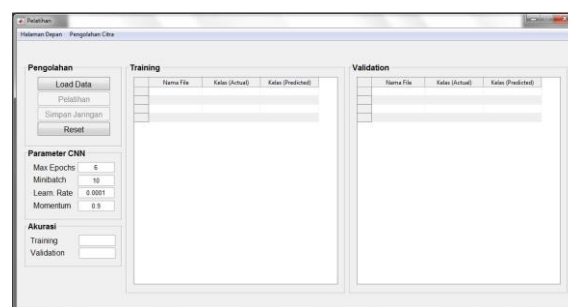
Halaman utama merupakan halaman yang pertama kali tampil ketika program dijalankan. Tampilan halaman utama dapat dilihat pada Gbr. 11



Gbr. 11 Halaman utama.

4.3 Halaman pelatihan


Halaman pelatihan adalah halaman untuk melakukan proses *training* dan validasi. Pada halaman pelatihan terdapat beberapa fitur diantaranya *load* data latih, *input* parameter, proses pelatihan dan validasi, simpan jaringan dan *reset*. Terdapat 4 (empat) parameter yang nilainya dapat diubah-ubah yaitu *epoch*, *mini-batch*, *learn rate* dan *momentum*. Pada akhir proses pelatihan akan ditampilkan nilai akurasi *training* dan validasi. Apabila nilai akurasi validasi > 70% maka jaringan akan disimpan dan digunakan untuk proses klasifikasi pada halaman pengolahan citra. Tampilan halaman pelatihan dapat dilihat pada Gbr. 12



Gbr. 12 Halaman pelatihan

4.4 Halaman pengolahan citra

Halaman pengolahan citra digunakan untuk klasifikasi hama dengan *input* citra daun tanaman kopi. Citra *input* akan diklasifikasi menggunakan jaringan yang disimpan ketika proses pelatihan. Pada halaman ini terdapat fitur *load* jaringan, *load* citra, klasifikasi dan *reset*. Tampilan halaman pengolahan citra ditunjukkan Gbr. 13



Gbr. 13 Halaman pengolahan citra.

4.5 Pengujian

Tabel IV menampilkan hasil pelatihan dengan dengan variasi nilai *input* parameter CNN. Pada pelatihan ini nilai parameter yang diubah-ubah ada dua yaitu *epoch* dan *mini-batch* sedangkan nilai *learn rate* dan *momentum* diberikan nilai yang tetap.

Id pelatihan PL04 memiliki nilai akurasi sebesar 80.56% yang merupakan nilai tertinggi, maka jaringan ini yang akan digunakan untuk proses klasifikasi pada halaman pengolahan citra.

TABEL IV
HASIL PELATIHAN

ID	Max. Epoch	Mini-batch	Learn Rate	Momentum	Akurasi (%)
PL01	6	5	0.0001	0.9	69.44
PL02	6	10	0.0001	0.9	75.00
PL03	8	10	0.0001	0.9	73.61
PL04	12	12	0.0001	0.9	80.56
PL05	12	15	0.0001	0.9	72.22

Terhadap jaringan dengan ID PL04 dilakukan pengujian menggunakan data *testing*. Data *testing* yang digunakan sebanyak 60 data dari 3 (tiga) kelas berbeda. Kemudian hasil *testing* dikonversi kedalam bentuk *confusion matrix* guna menghitung nilai *accuracy*, *precision* dan *recall*. Hasil konversi dapat dilihat pada tabel V.

TABEL V
CONFUSION MATRIX HASIL PENGUJIAN JARINGAN

CONFUSION MATRIX		PREDIKSI		
		<i>health</i>	<i>rust</i>	<i>red_spider_mite</i>
AKTUAL	<i>health</i>	17	2	1
	<i>rust</i>	1	15	4
	<i>red_spider_mite</i>	0	3	17

Dengan menggunakan data *confusion matrix* pada tabel IV dapat dihitung *accuracy* dengan persamaan (2), hasilnya sebagai berikut :

$$\begin{aligned}
 Accuracy &= \frac{17 + 15 + 17}{17 + 2 + 1 + 1 + 15 + 4 + 3 + 17} \\
 &= \frac{49}{60} \\
 &= 0.816
 \end{aligned}$$

Untuk menghitung *precision* dan *recall* masing kelas digunakan persamaan (3) dan (4). Kelas dengan *precision* tertinggi adalah *health* dengan nilai 0.94 dan kelas dengan nilai paling rendah adalah *rust* dengan nilai 0.75.

$$\begin{aligned}
 Precision_{health} &= \frac{17}{17 + (1 + 0)} \\
 &= \frac{17}{18} \\
 &= 0.94
 \end{aligned}$$

$$\begin{aligned}
 Precision_{rust} &= \frac{15}{15 + (2 + 3)} \\
 &= \frac{15}{20} \\
 &= 0.75
 \end{aligned}$$

$$\begin{aligned}
 Precision_{red_spider_mite} &= \frac{17}{17 + (1 + 4)} \\
 &= \frac{17}{22} \\
 &= 0.77
 \end{aligned}$$

Kelas dengan nilai *recall* tertinggi adalah *health* dan *red_spider_mite*, kedua kelas tersebut memiliki nilai sama yaitu 0.85. Kelas dengan nilai *recall* tertinggi paling rendah adalah *rust* dengan nilai 0.77.

$$\begin{aligned}
 Recall_{health} &= \frac{17}{17 + (2 + 1)} \\
 &= \frac{17}{20} \\
 &= 0.85
 \end{aligned}$$

$$\begin{aligned}
 Recall_{rust} &= \frac{15}{15 + (1 + 4)} \\
 &= \frac{15}{20} \\
 &= 0.77
 \end{aligned}$$

$$\begin{aligned}
 Recall_{red_spider_mite} &= \frac{17}{17 + (0 + 3)} \\
 &= \frac{17}{20} \\
 &= 0.85
 \end{aligned}$$

Hasil perhitungan secara keseluruhan dapat dilihat pada Tabel VI.

TABEL VI
PERHITUNGAN PRECISION DAN RECALL

Kelas	Precision	Recall
<i>health</i>	0.94	0.85
<i>rust</i>	0.75	0.77
<i>red_spider_mite</i>	0.77	0.85

V. KESIMPULAN

Berdasarkan penelitian yang dilakukan dapat disimpulkan arsitektur CNN Alexnet dapat diimplementasikan dengan platform pemrograman MATLAB. Nilai akurasi klasifikasi jaringan terhadap data *testing* mencapai 0.816 sehingga dapat disimpulkan arsitektur CNN Alexnet akurat untuk klasifikasi hama pada daun tanaman kopi.

Klasifikasi hama pada penelitian ini fokus pada daun tanaman kopi, kedepan dapat dikembangkan klasifikasi hama melalui bagian lain tanaman kopi misalnya batang, akar dan buah.

DAFTAR PUSTAKA

- [1] Y. LeCun, Y. Bengio, and G. Hinton, "Deep Learning," *Nature*, vol. 521, pp. 1–11, 2015.
- [2] M. S. Wibawa, "Pengaruh Fungsi Aktivasi , Optimisasi dan Jumlah *Epoch* Terhadap Performa Pengaruh Fungsi Aktivasi , Optimisasi dan Jumlah *Epoch* Terhadap Performa Jaringan Saraf Tiruan," *JSI*, vol. 11, pp. 1-9, 2016.
- [3] S. Ruder, "Overview of Gradient Descent Optimization Algorithms," arXiv:1609.04747v2, pp. 1-14, 2017.
- [4] G. Hinton, "A Practical Guide to *Training* Restricted Boltzmann Machines," Department of Computer Science University of Toronto, 2010.
- [5] I. Goodfellow, Y. Bengio and A. Courville, "Deep learning", The MIT Press, 2016.
- [6] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "ImageNet Classification with Deep Convolutional Neural Networks," *NeurIPS Proceedings*, 2012.
- [7] M. Alban and T. Gilligan, "Automated Detection of Diabetic Retinopathy using Fluorescein Angiography Photograph," Stanford University, 2016.
- [8] I. W. Suartika, A. Y. Wijaya, dan R. Soelaiman, "Klasifikasi Citra Menggunakan *Convolutional Neural Network* (CNN) pada Caltech 101," *Jurnal Teknik ITS* Vol. 5, No. 1, , 2016.
- [9] M. B. Bejiga, A. Zeggada, A. Nouffidj and F. Melgani, "A *Convolutional Neural Network* Approach for Assisting Avalanche Search and Rescue Operations with UAV Imagery". *Remote Sens.* pp 5, 2016.
- [10] S. Hijazi, R. Kumar and C. Rowen, "Using Convolutional Neural Networks for Image Recognition," *Remote Sens.* pp 7, 2015.
- [11] W. Caesarendra dan M. Ariyanto, "Panduan Belajar Mandiri MATLAB," Elex Media Computindo, 2011.
- [12] J. Han, M. Kamber and J. Pei, "Data Mining: Concepts and Techniques," Morgan Kaufmann Publishers, 2011.
- [13] L. Farokhah, "Implementasi K-Nearest Neighbor untuk Klasifikasi Bunga dengan Ekstraksi Fitur Warna RGB," *JTIK*, vol. 7, pp. 1129-1136, 2019.
- [14] E. K. Ratnasari, R. V. Hari Ginardi dan C. Fatichah, "Klasifikasi Penyakit Noda pada Citra Daun Tebu Berdasarkan Ciri Tekstur dan Warna Menggunakan Segmentation-Based Gray Level Cooccurrence Matrix dan LAB Color Moments oleh Ratnasari," *Jurnal Ilmiah Teknologi Sistem Informasi*, vol. 3, pp. 1-10, 2017.
- [15] B. Hidayat dan G. Hermawan, "Deteksi Hama Pada Daun Teh Dengan Metode *Convolutional Neural Network* (Cnn)," Tesis, UNIKOM, 2019.
- [16] E. N. Arrofiqoh, dan Harintaka, "Implementasi Metode *Convolutional Neural Network* Untuk Klasifikasi Tanaman Pada Citra Resolusi Tinggi," *JIG*, vol. 24, pp. 61-8, 2018.
- [17] Haryono, K. Anam dan A. Saleh, "Autentikasi Daun Herbal Menggunakan *Convolutional Neural Network* dan Raspberry Pi," *Jurnal Nasional Teknik Elektro dan Teknologi Informasi*, vol. 9, 2020.